Sortiranje i selekcija

© Goodrich, Tamassia, Goldwasser

Katedra za informatiku, Fakultet tehničkih nauka, Univerzitet u Novom Sadu 2019.

Sortiranje

- sortiranje: izmena redosleda elemenata u kolekciji tako da budu poređani od najmanjeg ka najvećem
- videli smo da red sa prioritetom može da posluži za sortiranje
 - selection sort je $O(n^2)$
 - insertion sort je $O(n^2)$
 - heap sort je $O(n \log n)$

Merge sort

- merge sort je primer divide-and-conquer šablona
 - \bullet $\mbox{divide}:$ podeli S na dva disjunktna podskupa S_1 i S_2
 - ullet recur: reši potproblem za S_1 i S_2
 - ullet conquer: kombinuj rešenja za S_1 i S_2 u rešenje za S
- bazni slučaj za rekurziju je skup veličine 0 ili 1

Merge sort

- merge sort je $O(n \log n)$, kao i heap sort
- za razliku od heap sorta
 - ne koristi pomoćnu strukturu podataka (RSP)
 - pristupa podacima sekvencijalno pogodno za sortiranje podataka na disku

Merge sort algoritam

- ullet sortira sekvencu S dužine n u tri koraka
- 1 divide: podeli S na S_1 i S_2 , svaki dužine n/2
- 2 recur: rekurzivno sortiraj S_1 i S_2
- 3 conquer: spoj sortirane S_1 i S_2 u sortiranu sekvencu

mergeSort(S)

```
Input: sekvenca S sa n elemenata Output: sortirana sekvenca S if \operatorname{len}(S) > 1 then (S_1, S_2) \leftarrow \operatorname{partition}(S, n/2) mergeSort(S_1) mergeSort(S_2) S \leftarrow \operatorname{merge}(S_1, S_2)
```

Spajanje sortiranih sekvenci

```
merge(A, B)
Input: sekvenca A i B sa n/2 elemenata svaka
Output: sortirana sekvenca A \cup B
  S \leftarrow \mathsf{prazna} \ \mathsf{sekvenca}
  while \neg A.isEmpty() \land \neg B.isEmpty() do
    if A.first().element() < B.first().element() then
       S.addLast(A.remove(A.first()))
    else
       S.addLast(B.remove(B.first()))
  while \neg A.isEmpty() do
    S.addLast(A.remove(A.first()))
  while \neg B.isEmpty() do
    S.addLast(B.remove(B.first()))
```

Spajanje sortiranih sekvenci

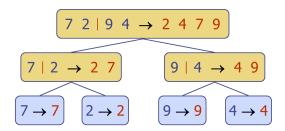
```
def merge(s1, s2, s):
  i = j = 0
  while i + j < len(s):
    if j == len(s2) or (i < len(s1) and s1[i] < s2[j]):
      s[i+j] = s1[i]
      i += 1
    else:
      s[i+j] = s2[i]
      i += 1
           i+i
                                          i+j
```

Merge sort u Pythonu

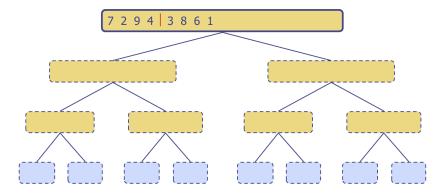
```
def merge_sort(s):
  n = len(s)
  if n < 2:
    return # already sorted
  # divide
  mid = n//2
  s1 = s[0:mid]
  s2 = s[mid:n]
  # recur
  merge_sort(s1)
  merge sort(s2)
  # conquer
  merge(s1, s2, s)
```

Stablo sortiranja

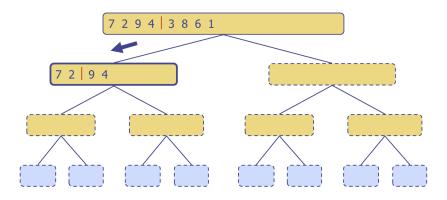
- izvršavanje merge sorta može se prikazati binarnim stablom
- čvor stabla predstavlja jedan rekurzivni poziv i čuva
 - nesortiranu sekvencu pre podele
 - sortiranu sekvencu nakon završetka
- koren je početni poziv funkcije
- listovi su pozivi sa podsekvence dužine 0 ili 1



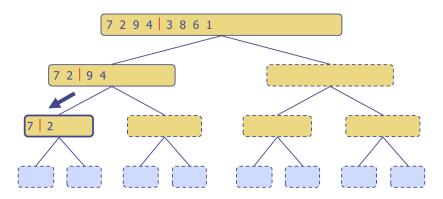
podela



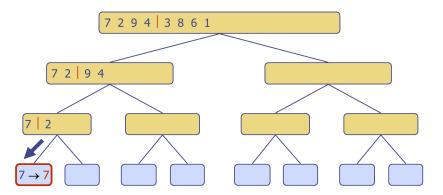
• rekurzija, podela



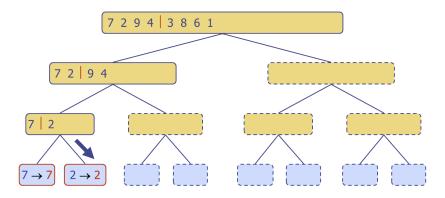
• rekurzija, podela



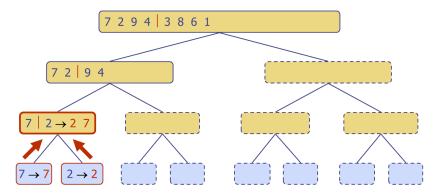
• rekurzija, bazni slučaj



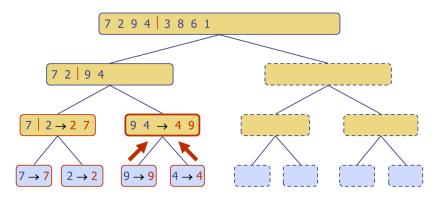
• rekurzija, bazni slučaj



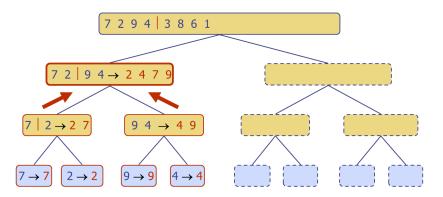
• spajanje



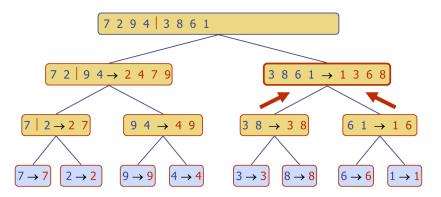
• rekurzija, ..., bazni slučaj, spajanje



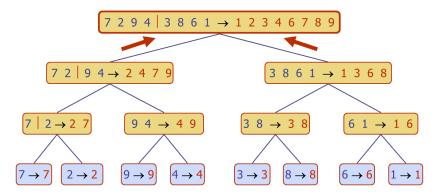
spajanje



• rekurzija, ..., spajanje, spajanje

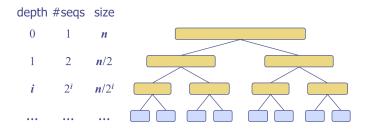


spajanje



Merge sort: performanse

- visina h stabla za merge sort je $O(\log n)$
 - delimo sekvencu na pola za svaku rekurziju
- ullet ukupan broj operacija na nivou i je O(n)
 - ullet delimo i spajamo 2^i sekvenci dužine $n/2^i$
 - ullet pravimo 2^{i+1} rekurzivnih poziva
- ukupno vreme izvršavanja je $O(n \log n)$



Algoritmi za sortiranje (za sada)

algoritam	vreme	napomene
selection		⊳ spor
	$O(n^2)$	⊳ in-place
		hd > za male sekvence (< 1 K)
insertion		⊳ spor
	$O(n^2)$	⊳ in-place
		hd > za male sekvence (< 1 K)
heap	$O(n \log n)$	⊳ brz
		⊳ in-place
		⊳ za velike sekvence (1K-1M)
merge	$O(n \log n)$	⊳ brz
		⊳ sekvencijalan
		hd > za ogromne sekvence $(>1M)$

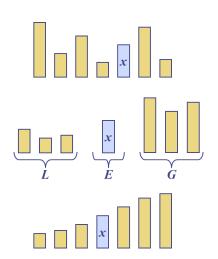
Merge sort: nerekurzivna varijanta $_1$

Merge sort: nerekurzivna varijanta $_2$

```
def merge(src, result, start, inc):
  """Merge src[start:start+inc] and src[start+inc:start+2*inc]."""
 end1 = start+inc
                                     # boundary for run 1
 end2 = min(start+2*inc, len(src)) # boundary for run 2
 x, y, z = start, start+inc, start # index into run 1, run 2, result
 while x < end1 and y < end2:
    if src[x] < src[y]:</pre>
     result[z] = src[x]
     x += 1
   else:
     result[z] = src[y]
     v += 1
    z += 1
                                     # increment z to reflect new result
 if x < end1:
   result[z:end2] = src[x:end1]
                                     # copy remainder of run 1 to output
 elif y < end2:
   result[z:end2] = src[y:end2]
                                     # copy remainder of run 2 to output
```

Quick sort

- quick sort je randomized podeli-pa-vladaj algoritam
- 1 divide: izaberi slučajan element x (pivot) i podeli S na
 - L: elementi manji od x
 - \bullet E: elementi jednaki x
 - ullet G: elementi veći od x
- 2 recur: sortiraj L i G
- 3 conquer: spoj sortirane L, E i G



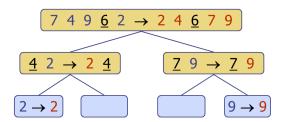
Particija ulaza

```
partition(S, p)
Input: sekvenca S i pozicija pivota p
Output: sekvence L, E, G
   L, E, G \leftarrow \mathsf{prazne} \ \mathsf{sekvence}
   x \leftarrow S.\mathsf{remove}(p)
   while \neg S.isEmpty() do
      y \leftarrow S.\mathsf{remove}(S.\mathsf{first}())
      if y < x then
         L.\mathsf{addLast}(y)
      else if y = x then
         E.\mathsf{addLast}(y)
      else
         G.\mathsf{addLast}(y)
   return L, E, G
```

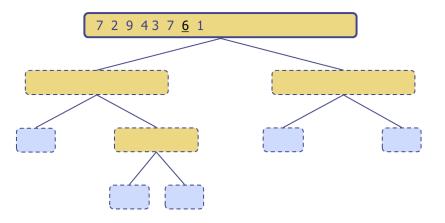
particija je O(n)

Stablo sortiranja

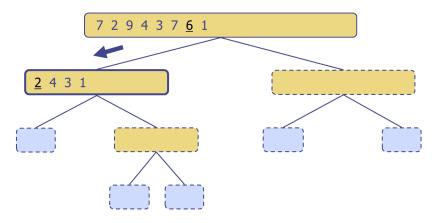
- izvršavanje quick sorta može se prikazati binarnim stablom
- čvor stabla predstavlja jedan rekurzivni poziv i čuva
 - nesortiranu sekvencu pre podele oko pivota
 - sortiranu sekvencu nakon završetka
- koren je početni poziv funkcije
- listovi su pozivi sa podsekvence dužine 0 ili 1



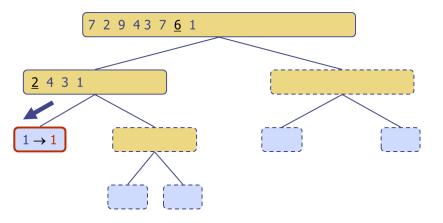
• izbor pivota



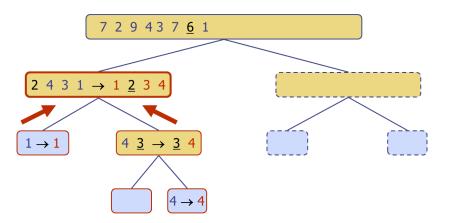
• particija, rekurzija, izbor pivota



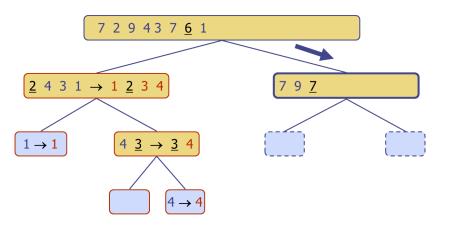
• particija, rekurzija, bazni slučaj



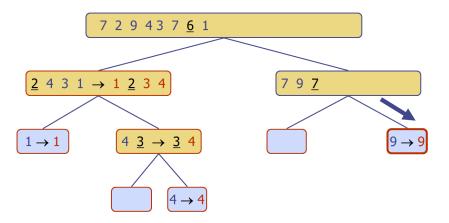
• rekurzija, ..., bazni slučaj, spajanje



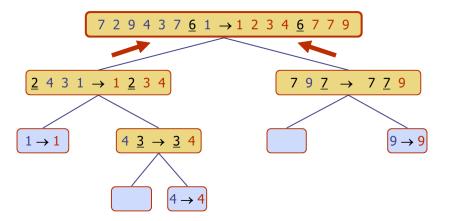
• rekurzija, izbor pivota



• particija, ..., rekurzija, bazni slučaj



• spajanje, spajanje

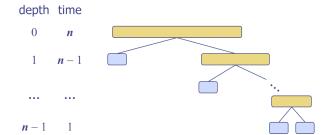


Performanse u najgorem slučaju

- najgori slučaj: kada je pivot najveći ili najmanji element
- ullet jedan od L ili G ima dužinu 0 a drugi dužinu n-1
- vreme izvršavanja je tada proporcionalno sumi

$$n+(n-1)+\ldots+2+1$$

ullet \Rightarrow najgori slučaj je $O(n^2)$



Očekivane performanse

- posmatrajmo rekurzivni poziv za sekvencu dužine s
 - dobar izbor: dužine L i G su obe manje od $s \cdot 3/4$
 - loš izbor: L ili G ima dužinu veću od $s \cdot 3/4$

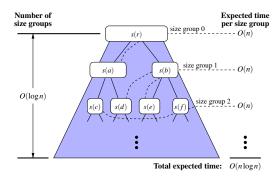


- ullet slučajan izbor pivota je dobar sa verovatnoćom 1/2
 - 1/2 mogućih pivota su dobar izbor



Očekivane performanse

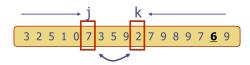
- ullet iz verovatnoće: očekivani broj bacanja novčića da bismo dobili k glava je 2k
- za čvor dubine i očekujemo
 - i/2 predaka su dobri izbori
 - veličina ulazne sekvence za tekući poziv je najviše $n \cdot (3/4)^{i/2}$
- ullet za čvor dubine $2\log_{4/3} n$ očekivana veličina ulaza je 1
- ullet očekivana visina stabla je $O(\log n)$
- broj operacija za čvorove iste dubine je O(n)
- ullet \Rightarrow ukupno očekivano vreme quick sorta je $O(n \log n)$



In-place particija

ullet koristimo indekse j i k da podelimo S na dva dela: L i $E \cup G$

- ponavljaj dok se j i k ne mimoiđu (k < j)
 - pomeraj i u desno dok ne naiđemo na element > x
 - ullet pomeraj k u levo dok ne naiđemo na element < x
 - zameni elemente na pozicijama i i k



Sortiranje i selekcija 22 / 45

In-place quick sort

```
def inplace quick sort(S, a, b):
  """Sort the list from S[a] to S[b] inclusive using quick-sort."""
  if a >= b: return
                                               # range is trivially sorted
 pivot = S[b]
                                               # last element of range is pivot
  left = a
                                               # will scan rightward
                                               # will scan leftward
  right = b-1
  while left <= right:
    # scan until reaching value equal or larger than pivot (or right marker)
    while left <= right and S[left] < pivot:</pre>
     left += 1
    # scan until reaching value equal or smaller than pivot (or left marker)
    while left <= right and pivot < S[right]:</pre>
     right -= 1
    if left <= right:
                                              # scans did not strictly cross
      S[left], S[right] = S[right], S[left] # swap values
      left, right = left + 1, right - 1 # shrink range
  # put pivot into its final place (currently marked by left index)
  S[left], S[b] = S[b], S[left]
  # make recursive calls
  inplace quick sort(S, a, left - 1)
  inplace quick sort(S, left + 1, b)
```

Sortiranje i selekcija 23 / 45

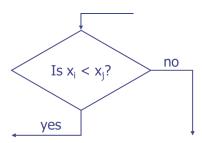
Algoritmi za sortiranje (za sada)

algoritam	vreme	napomene
selection	$O(n^2)$	⊳ in-place
		⊳ spor (dobar za male ulaze)
insertion	$O(n^2)$	
		⊳ spor (dobar za male ulaze)
heap	$O(n \log n)$	⊳ in-place
		⊳ brz (dobar za velike ulaze)
merge	$O(n \log n)$	⊳ sekvencijalan
		⊳ brz (dobar za ogromne ulaze)
quick	$O(n \log n)$	⊳ in-place, randomized
	očekivano	⊳ najbrži (dobar za velike ulaze)

Sortiranje i selekcija 24 / 45

Sortiranje zasnovano na poređenju

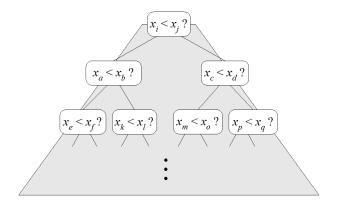
- mnogi algoritmi se zasnivaju na poređenju elemenata
 - porede se parovi elemenata
 - bubble, selection, insertion, heap, merge, quick...
- postoji li donja granica za vreme potrebno ovakvim algoritmima koji sortiraju x_1, x_2, \dots, x_n ?



Sortiranje i selekcija 25 / 45

Brojanje operacija poređenja

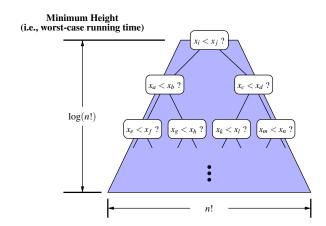
 svako pokretanje algoritma odgovara jednoj putanji koren→list u stablu odlučivanja



Sortiranje i selekcija 26 / 45

Stablo odlučivanja

- visina stabla odlučivanja je donja granica za vreme sortiranja
- svaka permutacija ulaza vodi do posebnog lista
- stablo ima n! listova \Rightarrow visina stabla je barem $O(\log(n!))$



Sortiranje i selekcija 27 / 45

Granica brzine

- ullet svaki algoritam koji se zasniva na poređenju je barem $O(\log(n!))$
- prema tome, vreme izvšavanja svakog algoritma je najmanje

$$\log n! \ge \log \left(\frac{n}{2}\right)^{\frac{n}{2}} = \frac{n}{2} \log \frac{n}{2}$$

• tj. svaki ovakav algoritam je $\Omega(n \log n)$

Sortiranje i selekcija 28 / 45

Bucket sort

- \bullet S je sekvenca n parova (ključ, element) sa ključevima u opsegu [0,N-1]
- bucket sort koristi ključeve kao indekse u pomoćnom nizu sekvenci (kanti) B
 - faza ${\bf 1}$: isprazni S premeštanjem svakog (k,o) u svoju kantu B[k]
 - \bullet faza 2: za $i=0,\dots,N-1$ premesti elemente kante B[i] na kraj S
- analiza:
 - faza 1 je O(n)
 - faza 2 je O(n+N)



• \Rightarrow bucket sort je O(n+N)

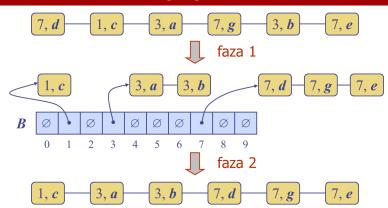
Sortiranje i selekcija 29 / 45

Bucket sort

```
bucketSort(S)
Input: sekvenca S sa int ključevima u opsegu [0, N-1]
Output: sortirana S
   B \leftarrow \mathsf{niz} \ \mathsf{od} \ N \ \mathsf{praznih} \ \mathsf{sekvenci}
   for all e in S do
      k \leftarrow e.\mathsf{key}()
      S.\mathsf{remove}(e)
      B[k].addLast(e)
   for i \leftarrow 0 to N-1 do
      for all e in B[i] do
         B[i].remove(e)
         S.\mathsf{addLast}(e)
```

Sortiranje i selekcija 30 / 45

Primer: opseg ključeva [0,9]





Sortiranje i selekcija 31 / 45

Osobine bucket sorta

- tip ključa: ključevi su isključivo integeri
- stabilno sortiranje: čuva se poredak među elementima sa istom vrednošću ključa
- proširenja

 - string ključevi iz konačnog skupa D mogućih vrednosti sortiramo stringove, pa njihove indekse koristimo kao ključeve

Sortiranje i selekcija 32 / 45

Leksikografski poredak

- d-torka je sekvenca od d ključeva (k_1, \dots, k_d)
- ključ k_i je i-ta dimenzija torke
- primer:
 - Dekartove koordinate 3D tačke su 3-torke
- leksikografski poredak dve d-torke se definiše rekurzivno:

$$\begin{aligned} (x_1,\dots,x_d) &< (y_1,\dots,y_d) \\ \Leftrightarrow \\ x_1 &< y_1 \vee x_1 = y_1 \wedge (x_2,\dots,x_d) < (y_2,\dots,y_d) \end{aligned}$$

• torke se porede po prvoj dimenziji, pa onda po drugoj, itd.

Sortiranje i selekcija 33 / 45

Leksikografsko sortiranje

- $\bullet\,$ neka je C_i komparator koji poredi dve torke po njhovoj i-toj dimenziji
- ullet neka je stableSort(S,C) algoritam koji koristi komparator C
- lexicographic sort sortira sekvencu d-torki u leksikografskom redosledu izvršavajući d puta algoritam stableSort, jednom za svaku dimenziju
- ullet lexicographic sort je O(dT(n)) gde je T(n) vreme stableSort-a

lexicographicSort(S)

```
Input: sekvenca S sa d-torkama
Output: sortirana S
for i \leftarrow d to 1 do
stableSort(S, C_i)
```

Sortiranje i selekcija 34 / 45

Leksikografsko sortiranje: primer

- (7, 4, 6) (5, 1, 5) (2, 4, 6) (2, 1, 4) (3, 2, 4) (2, 1, 4) (3, 2, 4) (5, 1, 5) (7, 4, 6) (2, 4, 6) (2, 1, 4) (5, 1, 5) (3, 2, 4) (7, 4, 6) (2, 4, 6)
- (2, 1, 4) (2, 4, 6) (3, 2, 4) (5, 1, 5) (7, 4, 6)

Sortiranje i selekcija 35 / 45

Radix sort

- radix sort je specijalizacija leksikografskog sortiranja koje koristi bucket sort kao stabilni sort algoritam za svaku dimenziju
- radix sort je primenljiv na torke gde su ključevi u svakoj dimenziji integeri iz [0,N-1]
- $\bullet \ \operatorname{radix} \ \operatorname{sort} \ \operatorname{je} \ O(d \cdot (n+N)) \\$

```
radixSort(S, N)
```

```
Input: sekvenca S sa d-torkama Output: sortirana S
```

for $i \leftarrow d$ to 1 do bucketSort(S, N)

Sortiranje i selekcija 36 / 45

Radix sort za binarne brojeve

ullet posmatramo sekvencu od n b-bitnih integera

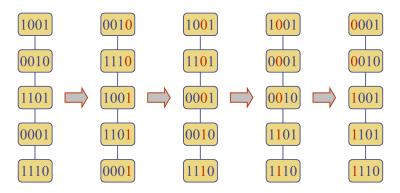
$$x = x_{b-1} \dots x_1 x_0$$

- ullet ove elemente tretiramo kao b-torku sa integerima u opsegu [0,1]
- ullet primenimo radix sort za N=2
- ova varijanta radix sorta je O(bn)
- → možemo sortirati niz 32-bitnih integera u linearnom vremenu!

Sortiranje i selekcija 37 / 45

Primer

• sortiramo sekvencu 4-bitnih integera



Sortiranje i selekcija 38 / 45

Problem selekcije

- za dati integer k i n elemenata x_1, \dots, x_n treba naći k-ti najmanji element
- ullet možemo sortirati niz za $O(n\log n)$ vreme i pristupiti k-tom elementu

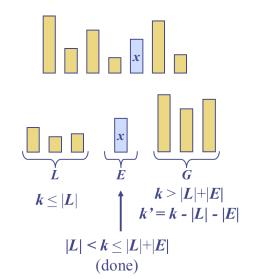
$$k=3$$
 7 4 9 6 2 \rightarrow 2 4 6 7 9

da li može brže?

Sortiranje i selekcija 39 / 45

Quick select

- quick select je randomized algoritam zasnovan na prune-and-search principu
 - prune: izaberi slučajan element x (pivot) i podeli S na L, E i G
 - search: zavisno od k, ili je element u E ili moramo da tražimo rekurzivno u L ili G



Sortiranje i selekcija 40 / 45

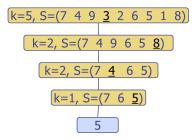
Particija ulaza

```
partition(S, p)
Input: sekvenca S i pozicija pivota p
Output: sekvence L, E, G
   L, E, G \leftarrow \mathsf{prazne} \ \mathsf{sekvence}
  x \leftarrow S.\mathsf{remove}(p)
  while \neg S.isEmpty() do
      y \leftarrow S.\mathsf{remove}(S.\mathsf{first}())
      if y < x then
         L.\mathsf{addLast}(y)
      else if y = x then
         E.\mathsf{addLast}(y)
      else
         G.addLast(y)
   return L, E, G
                             isto kao kod quick sorta \Rightarrow particija je O(n)
```

Sortiranje i selekcija 41 / 45

Vizuelizacija quick selecta

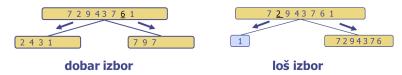
- quick select možemo prikazati kao putanju rekurzije
- svaki čvor je jedan rekurzivni poziv quickSelecta, čuva k i preostalu sekvencu



Sortiranje i selekcija 42 / 45

Očekivane performanse

- posmatrajmo rekurzivni poziv quick selecta za sekvencu dužine s
 - dobar izbor: dužine L i G su obe manje od $s \cdot 3/4$
 - loš izbor: L ili G ima dužinu veću od $s \cdot 3/4$



- ullet slučajan izbor pivota je dobar sa verovatnoćom 1/2
 - 1/2 mogućih pivota su dobar izbor



Sortiranje i selekcija 43 / 45

Očekivane performanse

- (1) iz verovatnoće: očekivani broj bacanja novčića da bismo dobili k glava je 2k
- (2) iz verovatnoće: očekivanje je linearna funkcija
 - E(X + Y) = E(X) + E(Y)
 - E(cX) = cE(x)
 - neka je T(n) vreme quick selecta
 - prema (2): $T(n) = T(3n/4) + n \cdot \text{(očekivani broj izbora do dobrog)}$
 - prema (1): T(n) = T(3n/4) + bn
 - ullet tj. T(n) je geometrijska progresija

$$T(n) \le 2bn + 2b(3/4)n + 2b(3/4)^2n + 2b(3/4)^3n \dots$$

- dakle T(n) je O(n)
- možemo rešiti problem selekcije u linearnom vremenu

Sortiranje i selekcija 44 / 45

Deterministička selekcija

- možemo uraditi selekciju i u najgorem slučaju za O(n)
- osnovna ideja: rekurzivno koristimo quick select da bismo našli dobrog pivota za quick select
 - ullet podeli S na 5 delova dužine n/5
 - nađi median u svakom podskupu
 - nađi median "malih" mediana rekurzivno

Sortiranje i selekcija 45 / 45